SUJET DE STAGE M2 • 6 MOIS

Agents IA et raisonnement logique pour la correction de modèles métaboliques régulés

Mots-clefs : Biologie des systèmes, programmation par ensembles-réponses (ASP), systèmes dynamiques hybrides, attracteurs, réparation de modèles, agent IA.

Encadrement : A. Siegel (IRISA, anne.siegel@irisa.fr), K. Thuillier (LMF, kerian.thuillier@lmf.cnrs.fr), en lien avec L. Paulevé (LaBRI).
Le stage peut se dérouler à l'IRISA (Rennes) ou au LMF (Gif-sur-Yvette), au choix de l'étudiant·e.

Profil recherché : Master 2 en informatique, mathématiques appliquées ou bioinformatique. Aucune connaissance préalable en biologie ni en ASP n'est requise ; le contexte biologique sera introduit en début de stage, avec l'appui des biologistes du projet. Le stage permettra d'acquérir une double expertise : programmation par ensembles-réponses (ASP + programmation linéaire, approches CEGAR), et conception et évaluation de workflows d'agents IA (LLM avec accès à des outils, recherche documentaire, contrôle des hallucinations). Une poursuite en thèse est possible. Un financement est disponible via l'ANR REGMETABO.

Contexte

Les bactéries sont des systèmes complexes, formés de processus interconnectés qui opèrent à des échelles de temps différentes. Ici, deux échelles de processus biologiques nous intéressent : le *métabolisme* et la *régulation génique*. Le *métabolisme* transforme les nutriments du milieu en énergie et en biomasse. Son activité est modélisée par un programme linéaire (*Flux Balance Analysis*, FBA) qui calcule une distribution de flux maximisant la production de biomasse. La *régulation génique* active ou inhibe les réactions et la transcription des gènes, ce qui permet à la bactérie de s'adapter à son environnement. Elle est modélisée par des règles booléennes, *e.g.* « si le régulateur A est actif et le nutriment B absent, alors le gène C est éteint ($C = \neg A \vee B$) ».

Dynamique du métabolisme régulé. Bien que fortement couplés, métabolisme et régulation sont le plus souvent étudiés séparément, et les modèles de métabolisme régulé restent rares. Le dernier modèle de régulation booléenne à l'échelle du génome d'*E. coli* date de 2004 [2]. Ces modèles sont simulés par la *regulated FBA* (rFBA [1]), qui simule la dynamique du métabolisme régulé en itérant sur deux étapes : *(i)* l'évaluation synchrone des règles, à partir de l'état du pas de temps précédent, détermine les réactions inhibées ; puis *(ii)* la résolution d'une FBA.

Pour reconstruire ces modèles, l'équipe a développé MERRIN [3], qui infère les règles de régulation à partir de connaissances *a priori* et de séries temporelles. MERRIN a cependant deux limites : *(i)* c'est une méthode *de novo*, qui réapprend le réseau à partir de zéro ; et *(ii)* les séries temporelles nécessaires sont coûteuses à produire.

Motivation biologique. Le dernier modèle de régulation d'*E. coli*, *iMC1010*, a été construit pour le réseau métabolique *iJR904* (2003, 904 gènes). Nous voulons l'adapter au réseau actuel, *iML1515* (2017, 1 515 gènes). Adapter la régulation à *iML1515* nécessite donc de corriger et d'apprendre de nouvelles règles. Plutôt que de tout réapprendre avec MERRIN, on cherche à identifier et corriger les règles fautives à partir de données plus simples à produire : les données *Biolog*. Les données *Biolog* donnent des informations qualitatives sur la croissance d'une population bactérienne : pour un ensemble de milieux et de souches, on sait si la population bactérienne a poussé ou non. Elles ne décrivent aucune trajectoire, seules les conditions initiales et le phénotype de croissance (croissance ou non) sont connues. Évaluer la compatibilité d'un modèle avec ces données demande donc un nouveau critère.

Objectifs

Travaux préliminaires. Nous avons proposé une sémantique de compatibilité fondée sur les *points fixes rFBA*, *i.e.* des états métaboliques régulés qui restent inchangés après réévaluation des règles de régulation. On prédit la croissance dans un milieu *si et seulement s'il* existe un point fixe avec croissance pour ce milieu. Cette sémantique est implémentée avec MerrinASP [4], le solveur ASP hybride (logique + linéaire) sur lequel repose

MERRIN ; elle permet de prédire la croissance et d'identifier les règles à modifier pour changer une prédiction.

Ce programme sert de base à un protocole de correction assisté par un agent IA (un LLM doté d'outils de recherche), en trois étapes : *(i)* MerrinASP identifie les gènes dont la modification de la règle rend le modèle compatible avec les données *Biolog* ; *(ii)* l'agent recherche dans la littérature les régulations connues de chaque candidat ; *(iii)* si les articles confirment une erreur, l'agent propose une nouvelle règle, sourcée par les DOI et des citations verbatim ; sinon, le candidat est écarté. Chaque correction entraîne un recalcul des points fixes, qui génère de nouveaux candidats. Sur *E. coli*, cette preuve de concept fait passer la compatibilité du modèle métabolique régulé avec 13 640 données *Biolog* de 69,66 % à 81,51 % par rapport au modèle de référence (81 règles corrigées, modèle propriétaire `Opus 5.5`).

Objectif 1 : formaliser le protocole LLM × MerrinASP. Le protocole actuel est une preuve de concept, sans formalisation ni implémentation robuste. Il s'agira de le spécifier : définir les entrées, sorties et garanties de chaque étape. Le défi central concerne la fiabilité de la recherche bibliographique réalisée par les agents IA : *comment prévenir les hallucinations et erreurs d'interprétation pour que les règles apprises soient fidèles à la littérature ?* En ouverture, la formalisation permettra également d'identifier, pour chaque sous-tâche, des LLMs spécialisés *open-weight* qui pourront remplacer les modèles propriétaires actuellement utilisés. C'est un objectif secondaire visant une plus grande sobriété de la méthode de correction et une plus grande autonomie vis-à-vis des modèles propriétaires.

Objectif 2 : sémantique des attracteurs rFBA. La sémantique de points fixes ne donne des garanties que pour des réseaux de régulation acycliques. Un réseau cyclique peut n'admettre aucun point fixe et converger vers un attracteur cyclique, *i.e.* une suite d'états rFBA qui se répète. La *Regulatory Steady-state Analysis* (RSA) [5] calcule de tels attracteurs, mais pour le seul réseau de régulation, sans couplage avec le métabolisme. L'objectif est de formaliser une sémantique d'attracteurs rFBA, ce qui demande notamment de formaliser la notion de *croissance* sur un attracteur cyclique, puis de l'implémenter avec MerrinASP. On comparera ensuite les candidats à la correction obtenus avec ceux de la sémantique de points fixes.

Application à *E. coli*. Le protocole sera évalué sur l'adaptation d'*iMC1010* au réseau *iML1515*, avec les 13 640 observations *Biolog* utilisées pour construire *iMC1010* [2]. Les corrections visent d'abord la validité biologique, les données expérimentales étant elles-mêmes sujettes aux erreurs. Une correction en accord avec la littérature pourrait donc déteriorer la compatibilité avec les données. On mesurera le nombre de règles corrigées, le taux de compatibilité avec les données, la reproductibilité des corrections d'une exécution à l'autre, et l'impact de la sémantique (points fixes ou attracteurs) sur les règles corrigées.

Références

[1] Covert M. W., Schilling C. H., Palsson B. Ø. Regulation of gene expression in flux balance models of metabolism. *J. Theor. Biol.* 2001.

[2] Covert M. W. et al. Integrating high-throughput and computational data elucidates bacterial networks. *Nature* 2004.

[3] Thuillier K. et al. MERRIN : MEtabolic regulation rule INference from time series data. *Bioinformatics* 2022.

[4] Thuillier K., Siegel A., Paulevé L. CEGAR-based approach for solving combinatorial optimization modulo quantified linear arithmetics problems. *AAAI* 2024.

[5] Marmiesse L., Peyraud R., Cottret L. FlexFlux : combining metabolic flux and regulatory network analyses. *BMC Syst. Biol.* 2015.